谈谈键值查找

2023-03

列举具体问题

- 扫描身份证后，即可检索出此人的个人信息。
- 又比如，用户登录网站时，输入了用户名，需要根据用户名比对密码是否正确。
- 然而，中国的人口比较多，所以这一过程需要较高效率的做法。

问题的抽象

- 设有二元组集合S，其元素形如$< x_i, y_i >$,且x_i互不相同。当给出x时，希望能够尽快得到对应的y,使得$\exists y, < x, y > \in S$,或者报告不存在这样的$x$。
- S中的元素个数为n，比较x_i的时间复杂度不可忽略。

<371311196603096659,潘>
<371726199610086519,杨>
<371082196504201469,曹>
<370921195408085086,吴>
<370502202010096292,黄>
<371302200207283081,萧>
<370303196405280684,罗>

生成测试数据

- 居民身份证号的每一位所包含的信息如右图所示。遵循这些规则，可以生成更有真实度的虚拟身份证号。
- 所以如果泄露了出生地和出生日期，性别等信息，那么身份证号只有2位是完全随机的，可以通过实名认证系统暴力破解得到。

“我会暴力匹配！”

- 逐个检查所有的身份证号，如果和输入的一致，那么就输出它对应的人的姓名。
- 设匹配每个身份证号需要的复杂度为$O(l)$，且最坏情况下需要遍历所有人的身份证号。那么时间复杂度为$O(nl)$。

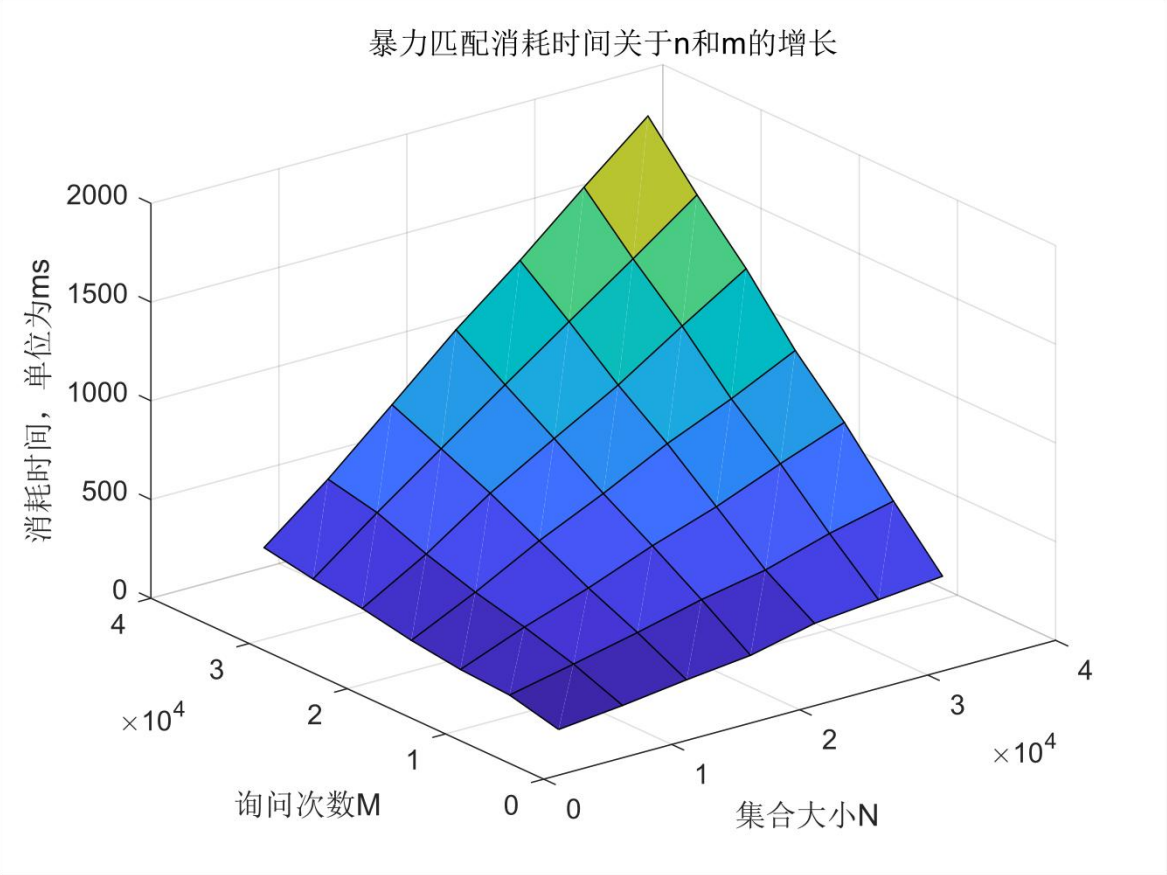

字典树

- 可以发现，这棵字典树用边来代表字母，而从根结点到树上某一结点的路径就代表了一个字符串。举个例子，1→4→8→12表示的就是字符串 `caa`。
- 有时需要标记插入进 字典树的是哪些字符串，每次插入完成时在这个字符串所代表的节点处打上标记即可。
- 演示字典树的工作原理

https://www.cs.usfca.edu/~galles/visualization/Trie.html

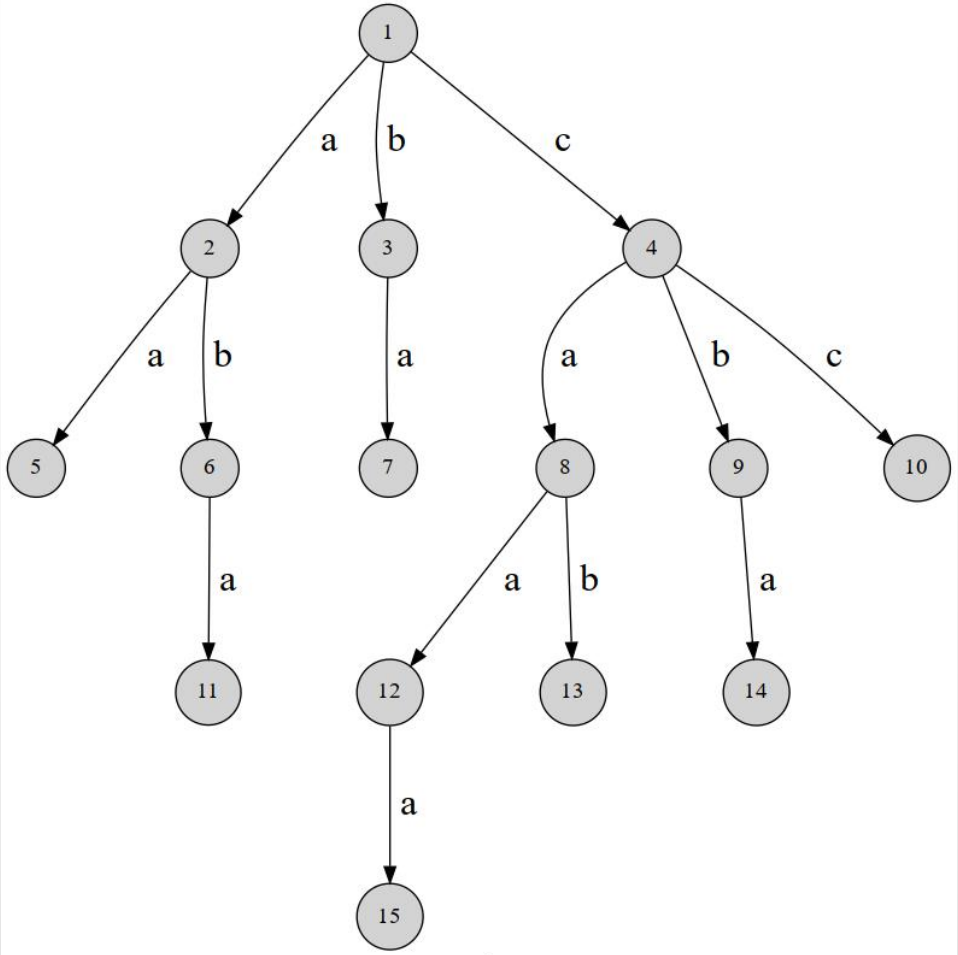

Trie

链表/哈希

- 演示动画
- https://www.cs.usfca.edu/~galles/visualization/OpenHash.html
- 拉链法也称开散列法（open hashing）。
- 拉链法是在每个存放数据的地方开一个链表，如果有多个键值索引到同一个地方，只用把他们都放到那个位置的链表里就行了。查询的时候需要把对应位置的链表整个扫一遍，对其中的每个数据比较其键值与查询的键值是否一致。如果索引的范围是M，哈希表的大小为 N，那么一次插入/查询需要进行期望$\frac{N}{M}$次比较。

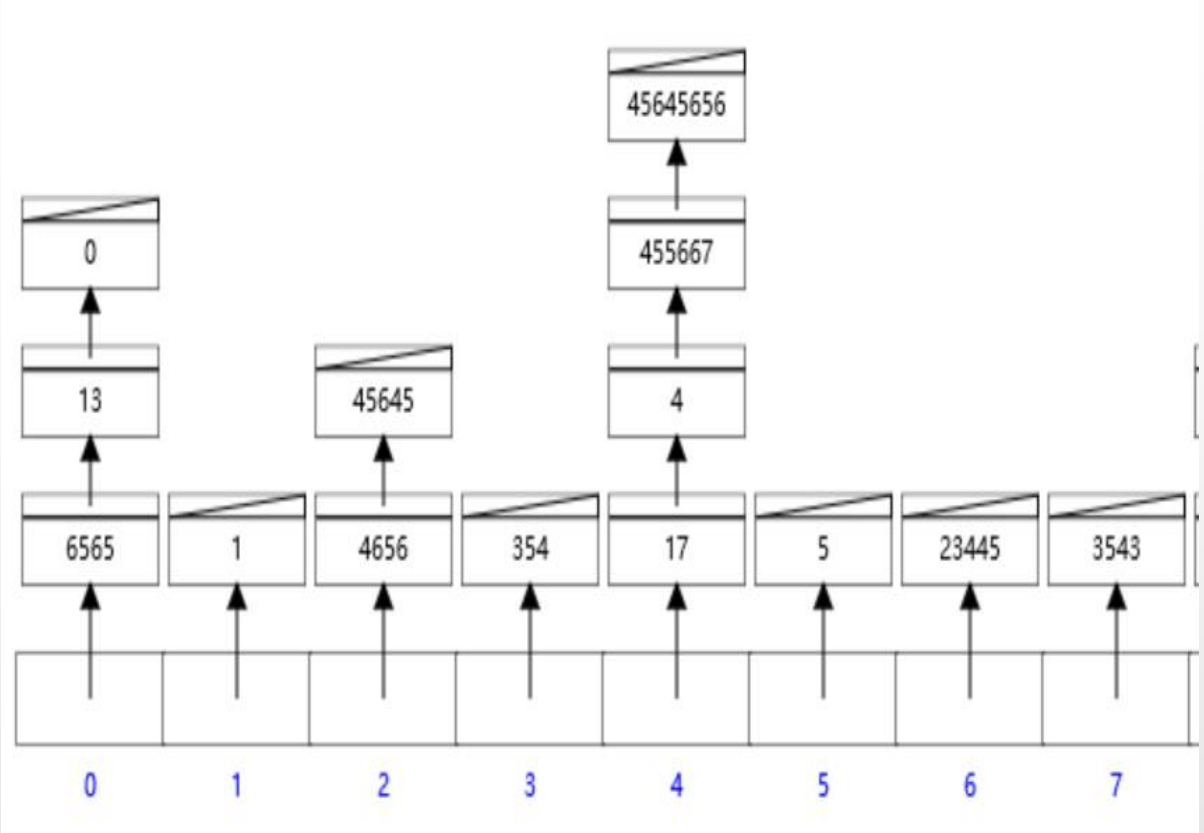

哈希和字典树的比较

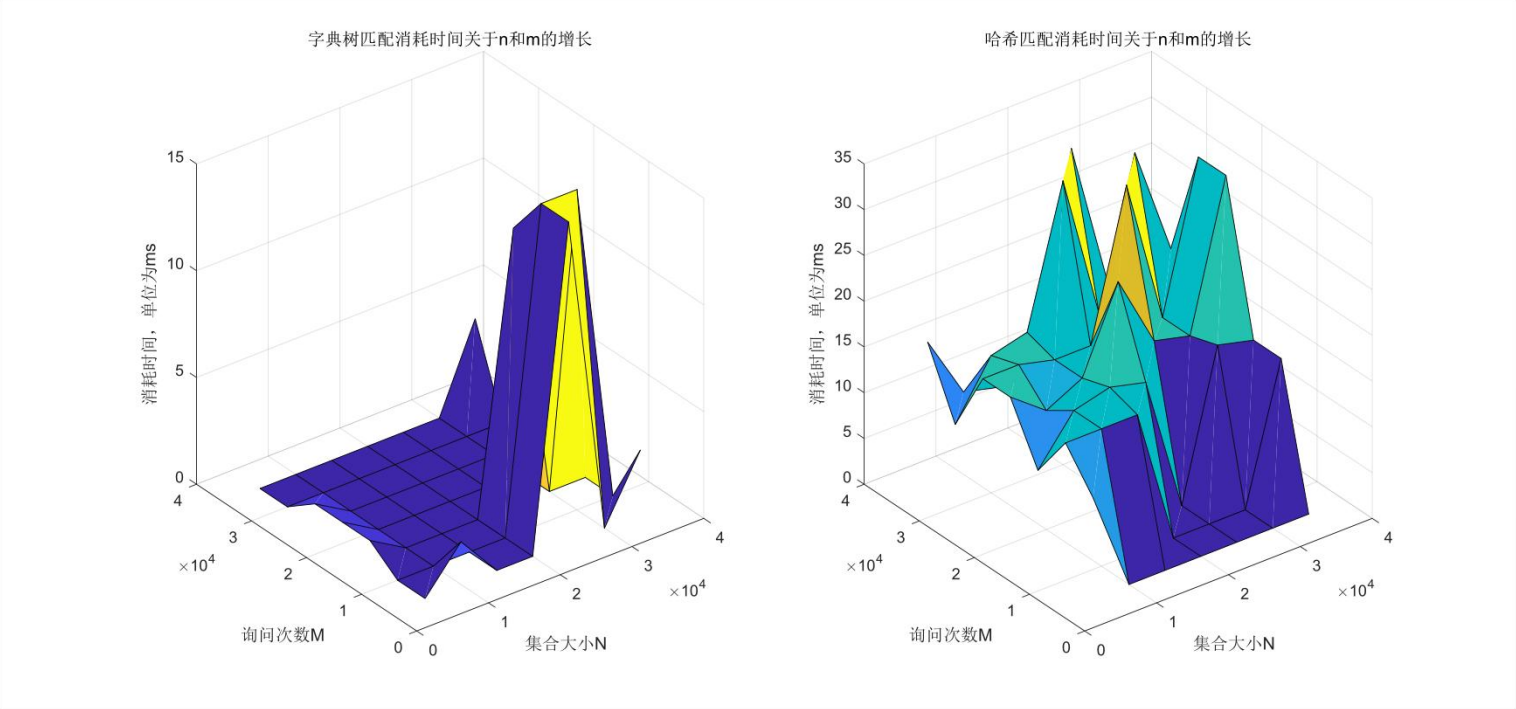

当集合大小N达到一定规模后，字典树的单次查找速度几乎保持稳定。而哈希则依然以一定速度增长。

综合分析

算法名称	时间复杂度	空间复杂度	应用场景	优点	缺点
暴力	$O(nl)$	$O(nl)$	数据量小	实现简单	速度慢
哈希	$O(\frac{n}{m})$	$O(M+nl)$	数据量较大	实现简单	占用空间较多
字典树	$O(l)$	$O(nl)$	数据量大	速度快	实现复杂，占用空间多